

Experimental Physics (II)

Experiment Notebook

Fundamental Python

Fitting Data of Simple Pendulum

Group 2

洪 瑜 B125090009

黃巧涵 B122030003

洪懌平 B102030019

2025/04/01

1 Preparatory Question

1.1 Under the small-angle approximation, why can the relation between period T and pendulum length L be expressed as $T = 2\pi\sqrt{L/g}$? Please explain the derivation process of this formula.

Using Newton's Second Law and Lagrangian Equation:

$$mL \frac{d^2\theta}{dt^2} = -mg\sin\theta \quad (1)$$

$$\frac{d^2\theta}{dt^2} + \frac{g}{L}\sin\theta = 0 \quad (2)$$

Suppose $\theta \sim 0$, i.e., under the small-angle approximation, $\sin\theta \sim \theta$, then Eq. 2 can be simplified to:

$$\frac{d^2\theta}{dt^2} + \frac{g}{L}\theta = 0 \quad (3)$$

可視為簡諧運動的微分方程

$$\theta(t) = A\sin(\omega t) + B\cos(\omega t) \quad (4)$$

where,

$$\omega = \sqrt{\frac{g}{L}} \quad (5)$$

$$T = \frac{2\pi}{\omega} = 2\pi\sqrt{\frac{L}{g}} \quad (6)$$

T 為系統完成一次完整振動所需的時間，即為週期

1.2 Through logarithmic transformation, the relationship between the period of a simple pendulum and its length can be converted into a linear relationship. Write out this transformation process and explain why such a transformation can help us use linear fitting to determine the gravitational acceleration g .

將Eq.6兩邊取對數：

$$\ln T = \ln(2\pi) + \frac{1}{2} \ln g \quad (7)$$

令

$$y = \ln T, \quad x = \ln L \quad (8)$$

$$A = \ln(2\pi) - \frac{1}{2} \ln g \quad (9)$$

可將Eq.9改寫為：

$$y = \frac{1}{2}x + A \quad (10)$$

斜率：

$$m = \frac{1}{2} \quad (11)$$

可將實驗數據用線性回歸求斜率，而

$$A = \ln(2\pi) - \frac{1}{2} \ln g \quad (12)$$

$$\ln g = 2(\ln(2\pi) - A) \quad (13)$$

擬合後的截距A可求重力加速度g：

$$g = \exp(2\ln(2\pi) - 2A) \quad (14)$$

1.3 What is the basic principle of least square fitting? Is `curve_fit` initially based on least square fitting?

1. 最小二乘法是用來找到一組最佳參數使模型 $f(x)$ 與觀測數據 (x_i, y_i) 的偏差最小化。概念為殘差平方和

$$S = \sum_i (y_i - f(x_i))^2 \quad (15)$$

y_i 為測量值、 $f(x_i)$ 為模型預測值、 $y_i - f(x_i)$ 為殘差。將模型參數優化使 S 最小，可找出最佳擬合結果。

2. 是的，`scipy.optimize.curve_fit`預設用非線性最小二乘法擬合數據，找最佳參數，使殘差平方最小；若數據有誤差，可透過`sigma`參數指定權重，`curve_fit`改用加權最小二乘法。

1.4 What is the basic principle of chi-square (χ^2) fitting? How does it differ from least square fitting?

1. 用來最小化卡方統計量 χ^2

$$\chi^2 = \sum_i \frac{(y_i - f(x_i))^2}{\sigma_i^2} \quad (16)$$

y_i 為測量值、 $f(x_i)$ 為模型預測值、 σ_i 為數據點的標準差。這個方法適用當數據有不同測量誤差時，因為它會給誤差較小的數據較高的權重，誤差較大的數據較低的權重。

2. 最小二乘法假設所有數據點的測量誤差相同，不考慮個別點的不確定性。 χ^2 擬合考慮測量誤差，誤差小的數據點影響較大，誤差大的數據點影響較小。若測量誤差相同， χ^2 擬合等於最小二乘法。

1.5 How to estimate χ^2 ? Please write the formula and explain the meaning of each variable.

$$\chi^2 = \sum_i \frac{(y_i - f(x_i))^2}{\sigma_i^2} \quad (17)$$

χ^2 為卡方統計量（衡量擬合優劣的指標）； y_i 為第 i 個數據點的實驗測量值； $f(x_i)$ 為第 i 個數據點的模型預測值； σ_i 為第 i 個數據點的測量誤差； N 為數據點總數。計算殘差 $y_i - f(x_i)$ 並平方，再除以誤差平方（ σ_i^2 ），加總全部即為 χ^2

意義：

1. χ^2 值越小，擬合效果越好
2. χ^2 接近 N ，則模型擬合合理
3. $\chi^2 \gg N$ ，表模型和數據不符
4. $\chi^2 \ll N$ ，可能誤差過大或過度擬合

1.6 What are the two general types of errors? Which type of error can be reduced by repeatedly conducting experiments

1. 系統誤差：可預測且固定的誤差。
 - (a) 儀器誤差：測量設備本身的限制或校準問題
 - (b) 方法誤差：測量方式的限制
 - (c) 環境誤差：外在因素的影響
2. 隨機誤差：不可預測且隨機變動的誤差。
 - (a) 讀數誤差：測量值因主觀判讀不同
 - (b) 外界干擾：例如空氣流動影響擺動時間測量
 - (c) 儀器靈敏度的限制：測量儀器的解析度有限，導致測量值有微小變動

隨機誤差可以透過多次實驗取平均值來降低影響，因為它的變動是隨機的，多次測量後平均值會更接近真實情況；但系統誤差無法透過多次實驗消除，需要透過改進儀器、調整測量方向，或校正數據來修正。

2 Experimental steps, preliminary results, and analysis

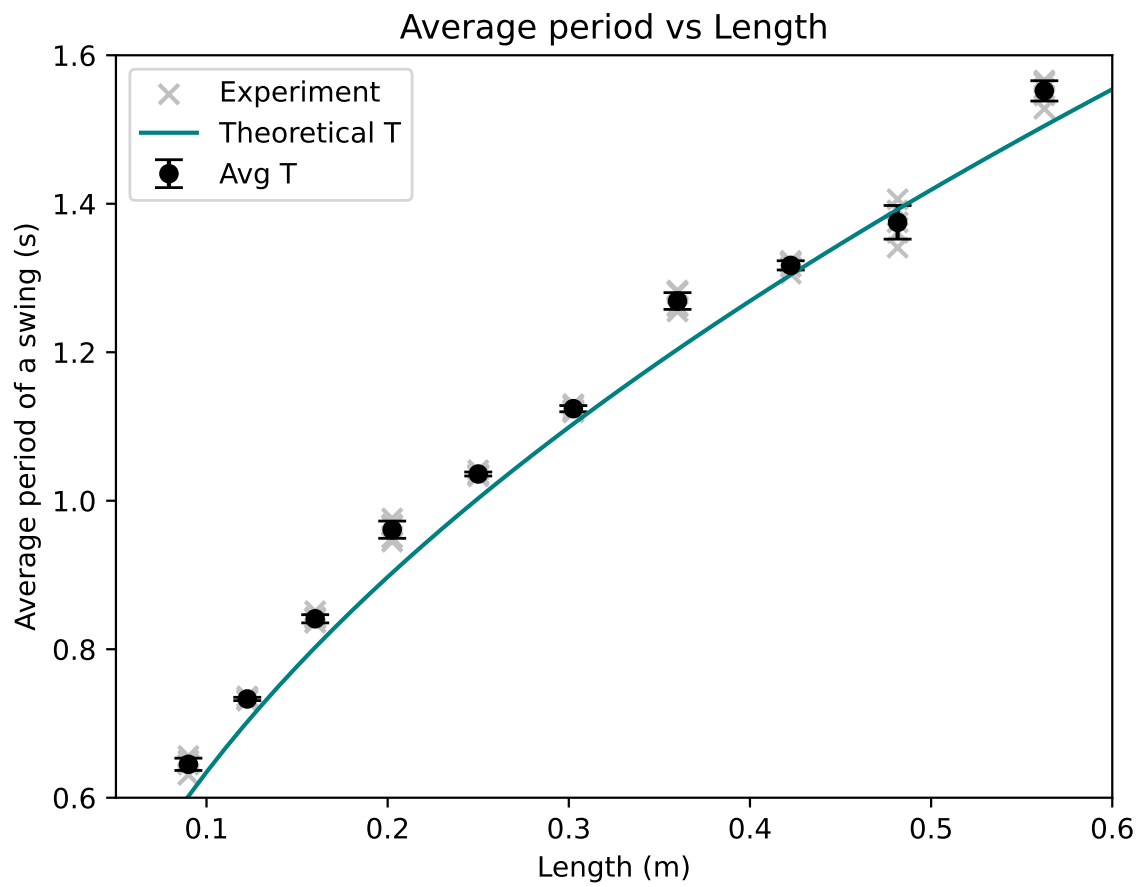


Figure 1: Experiment data

2.1 curve_fit

```
propt, _ = curve_fit(linear_function, np.log(pendulum_length_matrix), np.log(period_1swing.flatten()))
print(propt)
```

Figure 2: curve_fit(1)

使用curve_fit來擬合一條線性函數 $\log(T) = a \log(L) + b$ ；propt[0]為斜率，propt[1]為截距b。

```
plt.scatter(np.log(pendulum_length_matrix), np.log(period_1swing.flatten()), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(np.log(pendulum_length), np.log(avg_1period), yerr=std_1period_log, fmt='o', label='Avg T', color='k', capsize=5)
plt.plot(np.log(l_axis), linear_function(np.log(l_axis), *propt), color='orangered', label=f'curve_fit')
plt.plot(np.log(l_axis), np.log(t_ideal), label='Theoretical T', color='teal', linestyle='--')
plt.xlabel('log(Length) [m]')
plt.ylabel('log(Duration of a swing) [s]')
plt.title('Duration of a swing vs Length (Log-Log)')
plt.xlim(left=np.log(0.05), right=np.log(0.65))
plt.ylim(bottom=np.log(0.5), top=np.log(1.7))
plt.legend()
plt.savefig('./figures/curve_fit_log.pdf', transparent=True)
plt.show()
```

Figure 3: curve_fit(2)

繪製 Log-Log 圖，並比較擬合結果與理論值。實驗數據的對數值用銀色交叉符號顯示，error bar使用黑色圓點（如fig.6右圖）。

```
plt.scatter(pendulum_length_matrix, period_1swing.flatten(), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(pendulum_length, avg_1period, yerr=std_1period, fmt='o', label='Avg T', color='k', capsize=5)
plt.plot(l_axis, np.e**linear_function(np.log(l_axis), *propt), color='orangered', label=f'curve_fit')
plt.plot(l_axis, t_ideal, label='Theoretical T', color='teal', linestyle='--')
plt.xlabel('Length [m]')
plt.ylabel('Duration of a swing [s]')
plt.title('Duration of a swing vs Length')
plt.xlim(left=0.05, right=0.6)
plt.ylim(bottom=0.6, top=1.6)
plt.legend()
plt.savefig('./figures/curve_fit.pdf', transparent=True)
plt.show()
```

Figure 4: curve_fit(3)

繪製原始尺度的時間 vs. 擺長圖，已轉為線性尺度（fig.6左圖）。

```

g_fitted = np.e**(2*(np.log(2*np.pi) - propt[1]))
print(f'Ideal g = {g0.value:.3f} m/s^2')
print(f'Fitted g = {g_fitted:.3f} m/s^2')
print(f'Error = {np.abs(g_fitted - g0.value) / g0.value * 100:.3f}%')

```

Figure 5: curve_fit(4)

透過擬合結果估算重力加速度 g 。最後我們計算之結果 $g = 9.902(\frac{m}{s^2})$ ，與理論的 $g_0 = 9.807\frac{m}{s^2}$ 誤差0.975%。

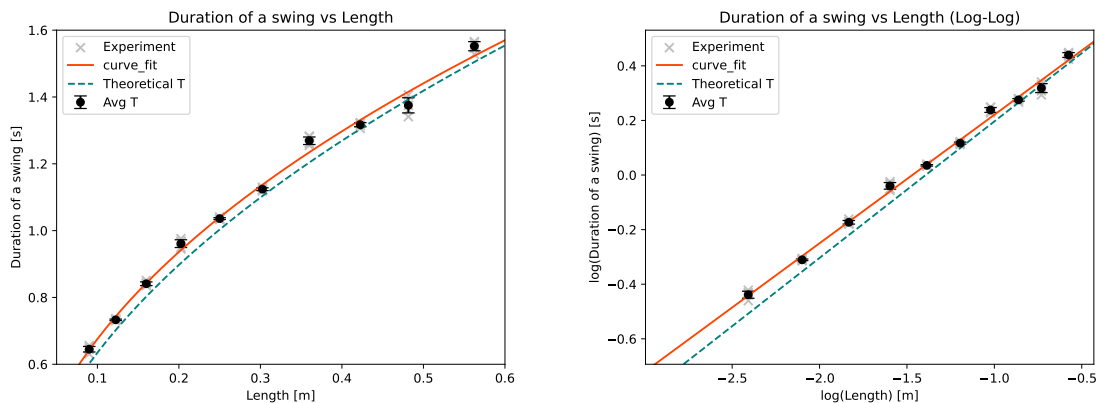


Figure 6: curve_fit

2.2 Least-squared fitting

```

A = np.vander(np.log(pendulum_length_matrix), 2)
C = np.diag(np.log(np.tile(std_1period, 5)) * np.log(np.tile(std_1period, 5)))
ATA = np.dot(A.T, A / (np.log(np.tile(std_1period, 5))**2)[: , None])
cov = np.linalg.inv(ATA)
w = np.linalg.solve(ATA, np.dot(A.T, np.log(period_1swing) / np.log(np.tile(std_1period, 5))**2))
print("Least-squares estimates:")
print("m = {0:.3f} ± {1:.3f}".format(w[0], np.sqrt(cov[0, 0])))
print("b = {0:.3f} ± {1:.3f}".format(w[1], np.sqrt(cov[1, 1])))
m_ls = w[0]
b_ls = w[1]

```

Figure 7: LS(1)

最小二乘法擬合 $\text{np.vander}(x, 2)$ 產生 Vandermonde矩陣，對應線性模型 $\log T = m \log L + b$ 。參數如下：

- C 是對角矩陣，考慮 \log 週期的誤差。
- $ATA = A^T C^{-1} A$ 是加權最小二乘法的矩陣。
- $\text{cov} = \text{np.linalg.inv}(ATA)$ 計算參數的不確定性（共變異矩陣）。
- $w = [m, b]$ 是最小二乘法解出來的參數。

```
plt.scatter(np.log(pendulum_length_matrix), np.log(period_1swing.flatten()), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(np.log(pendulum_length), np.log(avg_1period), yerr=std_1period_log, fmt='o', label='Avg T', color='k', capsize=5)
# plt.plot(np.log(l_axis), linear_function(np.log(l_axis), *propt), color='orangered', label=f'curve_fit')
plt.plot(np.log(l_axis), np.log(t_ideal), label='Theoretical T', color='teal', linestyle='--')
plt.plot(np.log(l_axis), np.dot(np.vander(np.log(l_axis), 2), w), linestyle="-", color='slateblue', label="LS")
plt.xlabel('log(Length) [m]')
plt.ylabel('log(Duration of a swing) [s]')
plt.title('Duration of a swing vs Length (Log-Log)')
plt.xlim(left=np.log(0.05), right=np.log(0.65))
plt.ylim(bottom=np.log(0.5), top=np.log(1.7))
plt.legend()
plt.savefig('./figures/ls_log.pdf', transparent=True)
plt.show()
```

Figure 8: LS(2)

Log-Log圖，檢查 LS擬合曲線是否與理論值相符；銀色交叉符號為實際對數值，黑色圓點表error bar（如fig.11右圖）。

```
plt.scatter(pendulum_length_matrix, period_1swing.flatten(), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(pendulum_length, avg_1period, yerr=std_1period, fmt='o', label='Avg T', color='k', capsize=5)
# plt.plot(l_axis, np.e**linear_function(np.log(l_axis), *propt), color='orangered', label=f'curve_fit')
plt.plot(l_axis, t_ideal, label='Theoretical T', color='teal', linestyle='--')
plt.plot(l_axis, np.e**np.dot(np.vander(np.log(l_axis), 2), w), linestyle="-", color='slateblue', label="LS")
plt.xlabel('Length [m]')
plt.ylabel('Duration of a swing [s]')
plt.title('Duration of a swing vs Length')
plt.xlim(left=0.05, right=0.6)
plt.ylim(bottom=0.6, top=1.6)
plt.legend()
plt.savefig('./figures/ls.pdf', transparent=True)
plt.show()
```

Figure 9: LS(3)

原始尺度圖，藍色實線（LS 擬合）與理論曲線（虛線）做比較，檢查擬合效果（fig.11左圖）。

```
g_fitted = np.e**(2*(np.log(2*np.pi) - w[1]))
print(f'Ideal g = {g0.value:.3f} m/s^2')
print(f'Fitted g = {g_fitted:.3f} m/s^2')
print(f'Error = {np.abs(g_fitted - g0.value) / g0.value * 100:.3f}%')
```

Figure 10: LS(4)

最後我們計算之結果 $g = 9.969(\frac{m}{s^2})$ ，與理論的 $g_0 = 9.807\frac{m}{s^2}$ 誤差1.660%

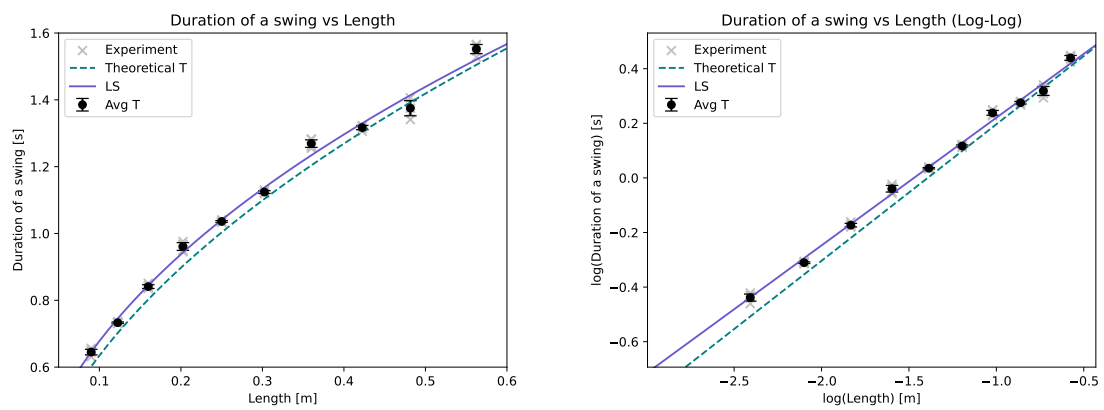


Figure 11: Least-squared fitting

2.3 χ^2 fitting

```
# Define the chi-squared function
def chi_sq_optimization(params, x_data, y_data, sigma):
    model = linear_function(x_data, *params) # Use your model function
    return chi_sq(y_data, model, sigma)

# Initial guess for the parameters
initial_guess = [0.5, 0.5] # Adjust based on your model

# Perform the optimization
result = minimize(chi_sq_optimization, initial_guess,
                  args=(np.log(pendulum_length_matrix), np.log(period_1swing.flatten()), np.log(np.tile(std_1period, 5))))

# Extract the optimized parameters
optimized_params = result.x
m_chisq = optimized_params[0]
b_chisq = optimized_params[1]
print("Optimized parameters:", optimized_params)
```

Figure 12: χ^2 fitting(1)

這部分是先定義chi-squared function，並定義：

params為我們要最佳化的參數（直線之斜率或截距）；

x_data 和 y_data 為輸入數據；

sigma為測量不確定性；

$linear_function(x_data, params)$ 為一條直線；（ $y = ax + b$ ）

$chi_sq(y_data, model, sigma)$ 為計算 χ^2 。

接著設定初始參數，先猜測 $a=0.5$ 、 $b=0.5$ ；並進行最小化 χ^2 。

而因為實驗要求擬合擺動週期與擺長的對數關係，所以需取對數，使其變線性關係（詳情見預習問題1、2）即可求得 a 、 b 。

最後把最佳化後的 a 、 b 顯示出來。

```
plt.scatter(np.log(pendulum_length_matrix), np.log(period_1swing.flatten()), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(np.log(pendulum_length), np.log(avg_1period), yerr=std_1period_log, fmt='o', label='Avg T', color='k', capsize=5)
# plt.plot(np.log(l_axis), linear_function(np.log(l_axis), *propt), color='orangered', linestyle='dashed',
#          label=f'curve_fit')
plt.plot(np.log(l_axis), np.log(t_ideal), label='Theoretical T', color='teal', linestyle='--')
# plt.plot(np.log(l_axis), np.dot(np.vander(np.log(l_axis), 2), w), "--k", label="LS")
plt.plot(np.log(l_axis), linear_function(np.log(l_axis), *optimized_params), linestyle="-", color='goldenrod', label="Chi-squared")
plt.xlabel('log(Length) [m]')
plt.ylabel('log(Duration of a swing) [s]')
plt.title('Duration of a swing vs Length (Log-Log)')
plt.xlim(left=np.log(0.05), right=np.log(0.65))
plt.ylim(bottom=np.log(0.5), top=np.log(1.7))
plt.legend()
plt.savefig('./figures/chisq_log.pdf', transparent=True)
plt.show()
```

Figure 13: χ^2 fitting(2)

這部分使用 $plt.scatter()$ 繪製實驗數據點；x軸為擺長取對數；y軸為單次擺動週期取對數。利用交叉符號點出個別數據點。

接著繪出理論曲線和 χ^2 擬合的曲線，並設定座標軸與標題及範圍；結果為fig.16右圖。

```
plt.scatter(pendulum_length_matrix, period_1swing.flatten(), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(pendulum_length, avg_1period, yerr=std_1period, fmt='o', label='Avg T', color='k', capsize=5)
# plt.plot(l_axis, np.e**linear_function(np.log(l_axis), *propt), color='orangered', linestyle='dashed',
#          label=f'curve_fit')
plt.plot(l_axis, t_ideal, label='Theoretical T', color='teal', linestyle='--')
# plt.plot(l_axis, np.e**np.dot(np.vander(np.log(l_axis), 2), w), "--k", label="LS")
plt.plot(l_axis, np.e**linear_function(np.log(l_axis), *optimized_params), linestyle="-", color='goldenrod', label="Chi-squared")
plt.xlabel('Length [m]')
plt.ylabel('Duration of a swing [s]')
plt.title('Duration of a swing vs Length')
plt.xlim(left=0.07, right=0.6)
plt.ylim(bottom=0.5, top=1.6)
plt.legend()
plt.savefig('./figures/chisq.pdf', transparent=True)
plt.show()
```

Figure 14: χ^2 fitting(3)

這部分繪製擺長與擺動週期的關係圖，但和上部分的對數-對數圖不同，這次是線性尺度。

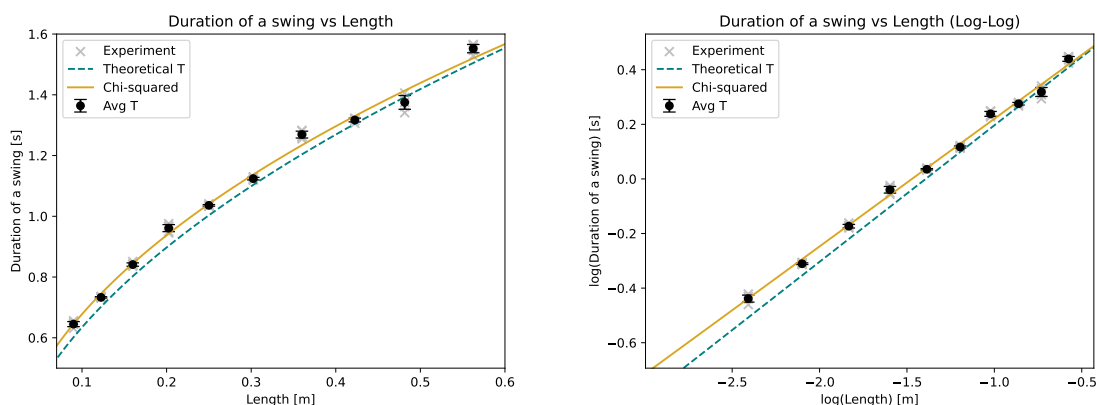
令x軸為擺長、y軸為擺動週期，用銀色交叉符號標出實驗數據，並繪出error bar（使用黑色圓點，表測量之不確定性）；最後劃出理論曲線和 χ^2 理論曲線與我們擬合出的結果（fig.16左圖）。

```
g_fitted = np.e**(2*(np.log(2*np.pi) - b_chisq))
print(f'Ideal g = {g0.value:.3f} m/s^2')
print(f'Fitted g = {g_fitted:.3f} m/s^2')
print(f'Error = {np.abs(g_fitted - g0.value) / g0.value * 100:.3f}%')
```

Figure 15: χ^2 fitting(4)

這部分透過 χ^2 擬合的結果估算重力加速度 g ，並和理論值（ g_0 ）比較。

計算方法參考預習問題1、2推導之公式。最後我們計算之結果 $g = 9.969(\frac{m}{s^2})$ ，與理論的 $g_0 = 9.807\frac{m}{s^2}$ 誤差1.660%。

Figure 16: χ^2 fitting

2.4 MCMC fitting

```
# Define the log-likelihood function
def log_likelihood(params, x_data, y_data, sigma):
    model = linear_function(x_data, *params)
    return -chi_sq(y_data, model, sigma)

# Define the log-prior function (flat priors in this case)
def log_prior(params):
    a, b = params
    if -10 < a < 10 and -10 < b < 10: # Adjust bounds as needed
        return 0.0 # Flat prior
    return -np.inf # Log(0) for invalid parameters

# Define the log-posterior function
def log_posterior(params, x_data, y_data, sigma):
    lp = log_prior(params)
    if not np.isfinite(lp):
        return -np.inf
    return lp + log_likelihood(params, x_data, y_data, sigma)
```

Figure 17: MCMC(1)

這部分是利用MCMC (Markov Chain Monte Carlo) 取樣，建立對數後驗分佈函數，並定義三個MCMC取樣所需之函數：

1. log-likelihood
2. log-prior
3. log-posterior

首先先定義log-likelihood，參數如下：

- params：模型的參數(a, b)（線性模型之斜率與截距）
- x_data ：自變數
- y_data ：因變數
- sigma：測量誤差

先使用`linear_function(x_data, params)`計算模型預測值；接著計算出 χ^2 ，再來由於likelihood function \mathcal{L} 通常與 $e^{-\frac{\chi^2}{2}}$ 成正比，可取對數得其值。

最後回傳log-likelihood作為評估參數的可能性。

再來利用Flat Prior設計log-prior，表示我們對參數(a, b)的先驗知識。

最後定義log-posterior，即為貝葉斯定理。

```
# Set up the MCMC sampler
ndim = 2 # Number of parameters (a and b)
nwalkers = 20 # Number of walkers
nsteps = 10000 # Number of steps
initial_guess = [m_chisq, b_chisq] # Initial guess for parameters
pos = initial_guess + 1e-4 * np.random.randn(nwalkers, ndim) # Initialize walkers
```

Figure 18: MCMC(2)

```
progress_file = "progress.h5"
backend = emcee.backends.HDFBackend(progress_file)

# Initialize the sampler
sampler = emcee.EnsembleSampler(nwalkers, ndim, log_posterior, backend=backend,
                                args=(np.log(pendulum_length_matrix),
                                       np.log(period_1swing.flatten()),
                                       np.log(np.tile(std_1period, 5))))

# Run the MCMC
sampler.run_mcmc(pos, nsteps, progress=True)
```

Figure 19: MCMC(3)

fig.18和fig.19是開始使用MCMC進行參數的擬合。

首先先設定MCMC參數與初始點（兩個參數、20個行走者、每個行走者執行1000步），並在初始化MCMC採樣氣後執行。

```
sampler = emcee.backends.HDFBackend("progress.h5")

# Extract the samples
samples = sampler.get_chain(discard=100, thin=15, flat=True)

# Print the results
m_mcmc, b_mcmc = np.mean(samples, axis=0)
print(f"MCMC results: m = {m_mcmc:.3f}, b = {b_mcmc:.3f}")
```

Figure 20: MCMC(4)

```
# Corner plot
fig_corner = corner.corner(samples, labels=['m', 'b'], show_titles=True, plot_datapoints=True, quantiles=[0.16, 0.5, 0.84])
# fig_corner.suptitle("Corner Plot of MCMC Results")
plt.savefig('./figures/corner.pdf', transparent=True)
plt.show()
```

Figure 21: MCMC(5)

fig.20和fig.21目的是讀取MCMC的取樣結果並分析參數的後驗分佈，最後繪製成圖。
提取MCMC採樣點部分的參數解釋：

- *discard* = 100為丟棄前100步，確保MCMC收斂後樣本才被使用。
- *thin* = 15每15步取一個樣本。
- *flat*=True將所有行走者的樣本合併成一個長列表。

最後計算MCMC擬合出的最佳參數（斜率 m 與截距 b ）。

此為診斷MCMC計算後的工具之一（fig.22）。

此段為MCMC的擬合結果（對數尺度），繪製出對數尺度的實驗數據與MCMC擬合曲線（為fig.26右圖）。

```

# Chain-step plot
fig_chain, axes = plt.subplots(ndim, figsize=(10, 7), sharex=True)
for i in range(ndim):
    ax = axes[i]
    ax.plot(sampler.get_chain()[ :, :, i], "k", alpha=0.3)
    if i == 0:
        ax.set_ylabel("m")
    else:
        ax.set_ylabel(f"b")
    ax.set_xlim(left=0, right=nsteps)
axes[-1].set_xlabel("Step number")
fig_chain.suptitle("Chain-Step Plot")
plt.savefig('./figures/chain.pdf', transparent=True)
plt.show()

```

Figure 22: MCMC(6)

```

plt.scatter(np.log(pendulum_length_matrix), np.log(period_1swing.flatten()), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(np.log(pendulum_length), np.log(avg_1period), yerr=std_1period_log, fmt='o', label='Avg T', color='k', capsize=5)
# plt.plot(np.log(l_axis), linear_function(np.log(l_axis), *propt), color='orangered', linestyle='dashed',
# ..... label=f'curve_fit')
plt.plot(np.log(l_axis), np.log(t_ideal), label='Theoretical T', color='teal', linestyle='--')
# plt.plot(np.log(l_axis), np.dot(np.vander(np.log(l_axis), 2), w), "--k", label="LS")
# plt.plot(np.log(l_axis), linear_function(np.log(l_axis), *optimized_params), "--b", label="Chi-squared")
plt.plot(np.log(l_axis), (m_mcmc*np.log(l_axis)+b_mcmc), color='lightcoral', linestyle='-', label=f'MCMC')
plt.xlabel('log(Length) [m]')
plt.ylabel('log(Duration of a swing) [s]')
plt.title('Duration of a swing vs Length')
plt.xlim(left=np.log(0.05), right=np.log(0.65))
plt.ylim(bottom=np.log(0.5), top=np.log(1.7))
plt.legend()
plt.savefig('./figures/mcmc_log.pdf', transparent=True)
plt.show()

```

Figure 23: MCMC(7)

```
plt.scatter(pendulum_length_matrix, period_1swing.flatten(), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(pendulum_length, avg_1period, yerr=std_1period, fmt='o', label='Avg T', color='k', capsize=5)
# plt.plot(l_axis, np.e**linear_function(np.log(l_axis), *propt), color='orangered', linestyle='dashed',
#          label=f'curve_fit')
plt.plot(l_axis, t_ideal, label='Theoretical T', color='teal', linestyle='--')
# plt.plot(l_axis, np.e**np.dot(np.vander(np.log(l_axis), 2), w), "--k", label="LS")
# plt.plot(l_axis, np.e**linear_function(np.log(l_axis), *optimized_params), "--b", label="Chi-squared")
plt.plot(l_axis, np.e**(m_mcmc*np.log(l_axis)+b_mcmc), color='lightcoral', linestyle='-', label=f'MCMC')
plt.xlabel('Length [m]')
plt.ylabel('Duration of a swing [s]')
plt.title('Duration of a swing vs Length')
plt.xlim(left=0.07, right=0.6)
plt.ylim(bottom=0.5, top=1.6)
plt.legend()
plt.savefig('./figures/mcmc.pdf', transparent=True)
plt.show()
```

Figure 24: MCMC(8)

此段為MCMC的擬合結果（線性尺度），繪製出線性尺度的實驗數據與MCMC擬合曲線（為fig.26左圖）。

```
g_fitted = np.e**(2*(np.log(2*np.pi) - b_mcmc))
print(f'Ideal g = {g0.value:.3f} m/s^2')
print(f'Fitted g = {g_fitted:.3f} m/s^2')
print(f'Error = {np.abs(g_fitted - g0.value) / g0.value * 100:.3f}%')
```

Figure 25: MCMC(9)

最後利用MCMC方法擬合得到 $g = 9.887(\frac{m}{s^2})$ ，與理論的 $g_0 = 9.807\frac{m}{s^2}$ 誤差0.823%。

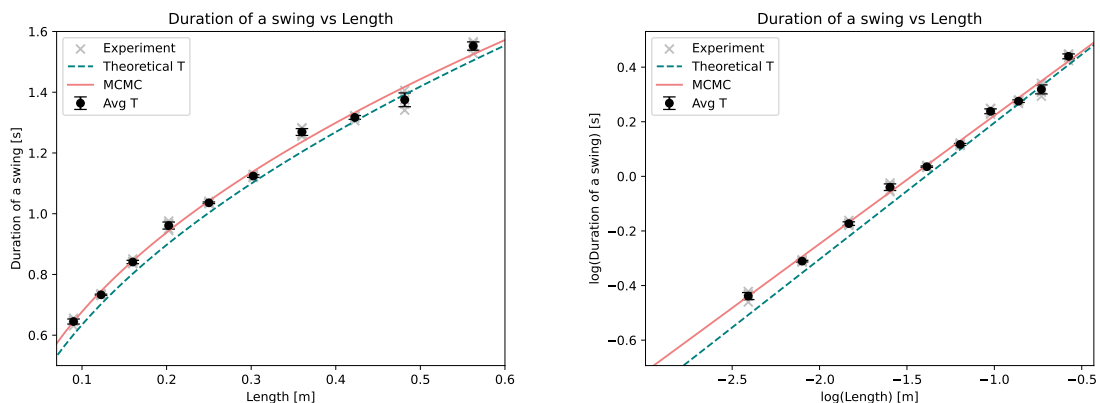


Figure 26: MCMC

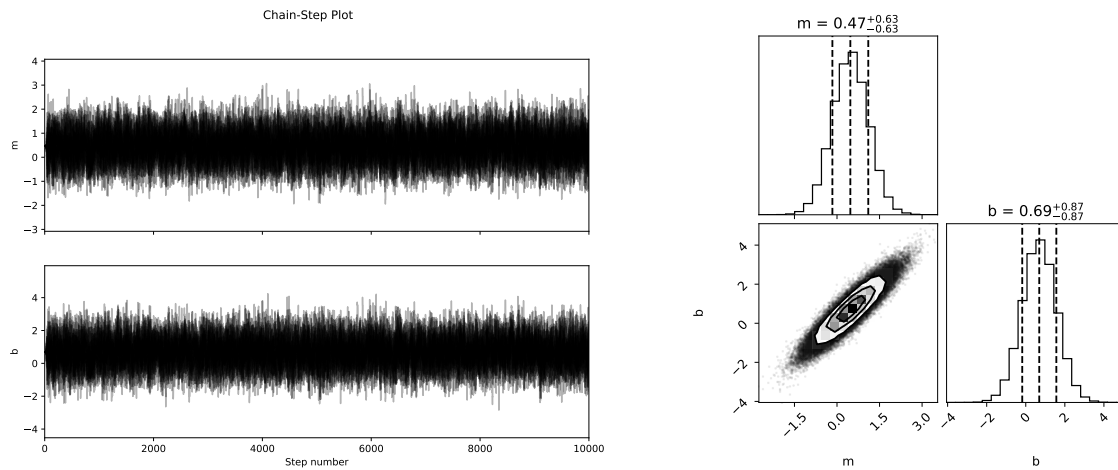


Figure 27: Chain-step plot and posterior corner plot

2.5 Comparison of all methods

```
plt.scatter(np.log(pendulum_length_matrix), np.log(period_1swing.flatten()), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(np.log(pendulum_length), np.log(avg_1period), yerr=std_1period_log, fmt='o', label='Avg T', color='k', capsizes=5)
plt.plot(np.log(l_axis), linear_function(np.log(l_axis), *propt), color='orangered', linestyle='dashed',
         label=f'curve_fit')
plt.plot(np.log(l_axis), np.log(t_ideal), label='Theoretical T', color='teal', linestyle='--')
plt.plot(np.log(l_axis), np.dot(np.vander(np.log(l_axis), 2), w), linestyle="--", color='slateblue', label="LS")
plt.plot(np.log(l_axis), linear_function(np.log(l_axis), *optimized_params), linestyle="--", color='goldenrod', label="Chi-squared")
plt.plot(np.log(l_axis), (m_mcmc*np.log(l_axis)+b_mcmc), color='lightcoral', linestyle='--', label=f'MCMC')
plt.xlabel('log(Length) [m]')
plt.ylabel('log(Duration of a swing) [s]')
plt.title('Duration of a swing vs Length')
plt.xlim(left=np.log(0.05), right=np.log(0.65))
plt.ylim(bottom=np.log(0.5), top=np.log(1.7))
plt.legend()
plt.savefig('./figures/all_log.pdf', transparent=True)
plt.show()
```

Figure 28: Comparison of all methods(1)

最後，我們比較每個方法的差異，分別繪製出最小平方法、卡方檢定、MCMC方法的線性擬合結果比較。

```
plt.scatter(pendulum_length_matrix, period_1swing.flatten(), s=50, marker='x', color='silver', label='Experiment')
plt.errorbar(pendulum_length, avg_1period, yerr=std_1period, fmt='o', label='Avg T', color='k', capsize=5)
plt.plot(l_axis, np.e**(linear function(np.log(l_axis), *propt), color='orangered', linestyle='dashed',
      label=f'curve_fit')
plt.plot(l_axis, t_ideal, label='Theoretical T', color='teal', linestyle='--')
plt.plot(l_axis, np.e**(np.dot(np.vander(np.log(l_axis), 2), w), linestyle="---", color='slateblue', label="LS")
plt.plot(l_axis, np.e**(linear function(np.log(l_axis), *optimized_params), linestyle="---", color='goldenrod', label="Chi-squared")
plt.plot(l_axis, np.e**(m_mcmc*np.log(l_axis)+b_mcmc), color='lightcoral', linestyle='--', label=f'MCMC')
plt.xlabel('Length [m]')
plt.ylabel('Duration of a swing [s]')
plt.title('Duration of a swing vs Length')
plt.xlim(left=0.07, right=0.6)
plt.ylim(bottom=0.5, top=1.6)
plt.legend()
plt.savefig('./figures/all.pdf', transparent=True)
plt.show()
```

Figure 29: Comparison of all methods(2)

此為三種方法的對數擬合結果比較。

```
print(f'Ideal g = {g0.value:.3f} m/s^2')
print("-----")
print(f'Fitted g (curve_fit) = {g_fitted:.3f} m/s^2')
print(f'Error (curve_fit) = {np.abs(g_fitted - g0.value) / g0.value * 100:.3f}%')
print("-----")
print(f'Fitted g (LS) = {np.e**(2*(np.log(2*np.pi) - b_ls)):.3f} m/s^2')
print(f'Error (LS) = {np.abs(np.e**(2*(np.log(2*np.pi) - b_ls)) - g0.value) / g0.value * 100:.3f}%')
print("-----")
print(f'Fitted g (Chi-squared) = {np.e**(2*(np.log(2*np.pi) - b_chisq)):.3f} m/s^2')
print(f'Error (Chi-squared) = {np.abs(np.e**(2*(np.log(2*np.pi) - b_chisq)) - g0.value) / g0.value * 100:.3f}%')
print("-----")
print(f'Fitted g (MCMC) = {np.e**(2*(np.log(2*np.pi) - b_mcmc)):.3f} m/s^2')
print(f'Error (MCMC) = {np.abs(np.e**(2*(np.log(2*np.pi) - b_mcmc)) - g0.value) / g0.value * 100:.3f}%')
```

Figure 30: Comparison of all methods(3)

此為三種方法推論出之重力加速度值。計算得：

- Ideal $g = 9.807\text{m/s}^2$
- $g(\text{curve_fit}) = 9.807\text{m/s}^2$
 $\text{Error}(\text{curve_fit}) = 0.823\%$
- $g(\text{LS}) = 9.969\text{m/s}^2$
 $\text{Error}(\text{LS}) = 1.660\%$
- $g(\text{Chi-squared}) = 9.969\text{m/s}^2$
 $\text{Error}(\text{Chi-squared}) = 1.660\%$
- $g(\text{MCMC}) = 9.887\text{m/s}^2$
 $(\text{MCMC}) = 0.823\%$

初步分析：

1. 方法比較：

curve_fit和MCMC兩種方法的擬合結果是 9.887m/s ，誤差 0.823%，而LS和 Chi-squared兩種方法的擬合結果是 9.969m/s ，誤差1.660%。

2. 擬合誤差分析：

curve_fit和MCMC方法給出的誤差較小（0.823%），說明這兩種方法較為精確，且與理論值的差異較小；LS 和 Chi-squared 方法的擬合誤差較大（1.660%），可能性為這兩種方法在這個問題中可能不如curve_fit或 MCMC方法適用，亦或是這些方法的假設或過程導致了稍微較大的誤差。

3. 初步結論：

curve_fit和MCMC擬合結果一致，且與理論值接近，說明它們可能能夠更準確地捕捉系統的行為。

4. 改進的可能性：

可以嘗試調整LS和Chi-squared方法的參數，或者檢查數據是否符合這些方法的假設。

3 具體說明除錯方法、可能遇到的問題

1. curve_fit 擬合

問題：初始參數敏感，容易發散或收斂至局部極值。

解決：提供合理的初始猜測值（可先手動擬合估算）；使用全局優化避免局部極值；檢查協方差矩陣評估參數不確定性。

2. 卡方計算

問題：數據誤差估計不準確，導致卡方值失真。

解決：確保誤差來源（如測量誤差、系統誤差）正確建模，或使用誤差重標定（error rescaling）。

3. 最小二乘法

問題：對異常值敏感，擬合結果可能偏差。

解決：使用加權最小二乘法或魯棒回歸（如RANSAC）降低異常值影響。

4. MCMC擬合

問題：收斂速度慢或陷入局部極值。

解決：調整步長、預燒期（burn-in），或改用更高效的採樣算法（如NUTS）。

5. 共通問題

(a) 模型偏差（如小角度近似不適用大擺角）：

解決：改用精確模型（如橢圓積分）或引入非線性修正項。

(b) 數值不穩定性（如除零、溢出）：

解決：對參數施加物理限制，或使用數值穩健算法。

(c) 過擬合：

解決：交叉驗證、使用正則化。